

## 7. Graphen

### 7.1. Motivation

Graphen sind ein mathematisches Modell, mit dem sich Algorithmen zur Lösung verschiedener Aufgaben formulieren lassen. Gelingt es, eine konkrete Aufgabe, wie das Heraussuchen optimaler Zugverbindungen aus einem Fahrplan, untereinander abhängige Arbeiten in einer sinnvollen Reihenfolge anzuordnen oder einen Garbage Collector für eine Software-Laufzeitumgebung zu planen, mit einem Graphen-Modell zu formulieren, kann man die dafür bekannten Algorithmen verwenden. Da Graphen eine einfache und gleichzeitig mächtige Struktur sind, lassen sich viele Aufgaben damit modellieren. Die wichtigsten davon sind Thema dieses Kapitels.

### 7.2. Lernziele

- Sie können Datenstrukturen zur Speicherung von Graphen konzeptuell beschreiben, Stärken und Schwächen angeben und in Bezug auf eine bestimmte Aufgabe auswählen.
- Sie können mindestens eine Datenstruktur zur Speicherung von Graphen in Java implementieren.
- Sie können Algorithmen auf Graphen zur *Topologischen Sortierung*, zum systematischen *Absuchen*, und zur *Bestimmung eines kürzesten Weges* konzeptuell beschreiben und in Java implementieren.

### 7.3. Graphen – Definitionen

Auf eine grundsätzliche Einführung von *Graphen* soll an dieser Stelle verzichtet werden. Zur Auffrischung bzw. zum Nachlesen grundlegender Definitionen und Eigenschaften, die aus der Mathematik bekannt sein sollten, steht ein separates Blatt zur Verfügung.

### 7.4. Datenstrukturen zum Speichern von Graphen

Es gibt verschiedene Arten, Graphen im Speicher eines Computers in Datenstrukturen zu speichern. Die Auswahl hängt von den Eigenschaften der konkreten Daten ab, wie der absoluten Anzahl von Knoten und Kanten sowie dem Verhältnis dieser Zahlen; weiter davon, ob oder wie häufig Knoten oder Kanten hinzugefügt oder entfernt werden sollen. Schliesslich spielt es auch noch eine wesentliche Rolle, welche Algorithmen auf der Datenstruktur ausgeführt werden sollen.


#### 7.4.1. Adjazenzmatrix

Adjazenzmatrizen stellen Kanten zwischen Knoten als Wert in einer quadratischen Matrix dar. Deren Dimension wird durch die Anzahl der Knoten vorgegeben: Bei  $n$  Knoten ergibt sich eine  $n \times n$ -Matrix.

Bei gewichteten Graphen werden als Werte die entsprechenden Kantengewichte eingesetzt, bei ungewichteten Graphen genügen Wahrheitswerte. Typische Deklarationen in Java wären also:

```
int[][] g = new int[N][N]; // gewichteter Graph
boolean[][] g = new boolean[N][N]; // ungewichteter Graph
```

Der unten gezeichnete Graph ist daneben in einer (zu ergänzenden) Adjazenzmatrix dargestellt. Die Matrix zeigt durch den Wert 5 in Zeile 1 und Spalte 2 an, dass eine Kante mit Gewicht 5 vom Knoten 1 zum Knoten 2 führt. In der Gegenrichtung (Zeile 2, Spalte 1) gibt es keine Kante, was durch einen Strich angezeigt wird.



	1	2	3	4	5	6
1	-	5	-	4	-	-
2	-	-				
3	4	3				
4						
5						
6						

Bei der Implementierung in Software stellt sich die Frage, wie die Tatsache, dass keine Kante existiert, repräsentiert werden soll. Da Matrizen mit Element-Typ *int* benutzt werden sollen, ist die von uns hier verwendete Darstellung "-" nicht möglich.

Die Lösung des Problems hängt davon ab, wie die Kantengewichte interpretiert werden sollen.

- Handelt es sich um Distanz- oder Kostenangaben, so bedeutet eine nicht vorhandene Kante eine unendlich weite bzw. unendlich teure Verbindung. Daher sollte ein möglichst grosser Wert gewählt werden. In der Praxis: *Integer.MAX\_VALUE*.
- Handelt es sich um Kapazitätsangaben (z.B. wie viel Energie eine Stromleitung pro Zeiteinheit transportieren kann, wie viele Autos pro Stunde den Gotthardtunnel passieren können, oder wie viele Bit pro Sekunde eine Datennetzwerkverbindung übermitteln kann), so bedeutet eine nicht vorhandene Kante eine Verbindung mit der Kapazität 0. Daher wird dann der Wert 0 für die Darstellung einer nicht-bestehenden Kante verwendet.

Mit den beschriebenen Werten wird erreicht, dass Algorithmen keine Fallunterscheidungen machen müssen, sondern sich auf Grund des Wertes für sehr hohe Kosten bzw. sehr niedrige Kapazität „automatisch“ so verhalten, als gäbe es die entsprechende Kante gar nicht.

Im Fall von ungewichteten Graphen stellt sich das oben diskutierte Problem natürlich gar nicht, denn es wird mit den Werten *true* und *false* angezeigt, ob eine Kante existiert.

Für ungerichtete Graphen ist die Adjazenzmatrix symmetrisch. Das heisst, es gilt  $A = A^T$ .<sup>1</sup>

#### 7.4.2. Kantentabelle

Eine Kantentabelle ist eine Liste, mit je einem Eintrag pro Kante im Graphen. Jeder Eintrag enthält Start- und Zielknoten der Kante sowie bei gewichteten Graphen das Gewicht. Eine solche Liste kann man als Tabelle oder als verlinkte Liste speichern. Für letzteren Fall bietet sich als Typdeklaration eine *Linked List* von Objekten des Typs *Edge* an:

```
class Edge {
    int from, to, weight;
}
```

Untenstehende (zu ergänzende) Kantentabelle zeigt denselben Graphen wie im Abschnitt 7.4.1. Die Kante von 1 nach 2 mit Gewicht 5 ist als Beispiel bereits eingetragen.

from	1							
to	2							
weight	5							


Im Falle von ungerichteten Graphen kann man entweder jede Kante doppelt in die Tabelle eintragen (einmal für jede Richtung) oder die Werte von *from* und *to* jeweils gleich, das heisst gleichzeitig als Start- und Zielknoten behandeln.

#### 7.4.3. Verbindungslisten (Adjazenzlisten)

Verbindungslisten beschreiben für jeden Knoten die von ihm wegführenden Kanten, bzw. die direkt erreichbaren Nachbarknoten in einer Liste. Es brauchen in diesem Fall nur noch die jeweiligen Zielknoten und ein allfälliges Gewicht gespeichert zu werden.

Nebenstehende (zu ergänzende) Datenstruktur bildet den Graphen aus Abschnitt 7.4.1 als Adjazenzlisten ab. Die Kante von 1 nach 2 mit Gewicht 5 ist als Beispiel eingetragen. Vom Knoten 5 führen keine Kanten weg.

Verbindungslisten für ungerichtete Graphen brauchen doppelte Einträge für jede Kante, denn diese müssen für jeden der beiden Endknoten registriert werden.



<sup>1</sup>  $A^T$  bezeichnet die *transponierte* Matrix von A, d.h. die Matrix, die sich durch Spiegelung von A an der Hauptdiagonalen ergibt.

## 7.5. Topologisches Sortieren


Allgemein für Graphen formuliert lautet die Aufgabenstellung für das *Topologische Sortieren*: Gegeben sei ein *gerichteter Graph*, finde eine *topologische Ordnung* seiner Knoten.

**Definition:** Eine topologische Ordnung ist eine Reihenfolge  $(v_1 v_2 v_3 \dots v_n)$  von Knoten, so dass ein Knoten  $v_i$  vor dem Knoten  $v_j$  erscheint, falls es einen Pfad von  $v_i$  nach  $v_j$  gibt.

**Bemerkung:** Damit eine topologische Ordnung existiert, muss der Graph zyklensfrei sein.<sup>2</sup>

Topologische Ordnungen sind i.a. nicht eindeutig. Für den nebenstehenden Graphen gibt es vier verschiedene Ordnungen:

1 – 2 – 3 – 4 – 5 – 6 – 7 , 1 – 3 – 2 – 4 – 5 – 6 – 7,  
1 – 2 – 3 – 4 – 6 – 5 – 7 , 1 – 3 – 2 – 4 – 6 – 5 – 7.



Algorithmen zum Ermitteln einer solchen Ordnung, also zum topologischen Sortieren, verwenden den *Eingangsgrad* (*in degree*) der Knoten:

$$\text{indeg}(x) = |\{ y \mid \langle y, x \rangle \in E \}|$$

die Anzahl Elemente der Menge aller Knoten  $y$ , von denen eine Kante zum Knoten  $x$  führt

Eine Folge topologisch sortierter Knoten kann schrittweise aufgebaut werden, indem wiederholt ein (beliebiger) noch nicht eingeordneter Knoten mit Eingangsgrad 0 daran angehängt wird.

Es ergibt sich daraus folgender Algorithmus:

1. Für alle Knoten den Eingangsgrad bestimmen
2. Alle Knoten mit Eingangsgrad 0 in einem *Set* sammeln
3. Solange das *Set* der Knoten mit Eingangsgrad 0 nicht leer ist,
  - i. Einen Knoten  $x$  dem *Set* entnehmen und an die Folge anhängen
  - ii. Bei allen Knoten  $y$ , zu denen von  $x$  eine Kante führt, den Eingangsgrad um 1 reduzieren. Wird dabei der Eingangsgrad von  $y$  zu 0,  $y$  dem *Set* hinzufügen.
4. Sind alle Knoten des Graphen verarbeitet, ist dabei eine topologische Ordnung entstanden. Sind noch unverarbeitete Knoten übrig, hat aber keiner davon Eingangsgrad 0, ist der Graph zyklisch und es gibt keine topologische Ordnung dafür.

*Aufwand (bei  $n$  Knoten und  $m$  Kanten):*

- Der beschriebene Algorithmus muss zunächst alle Knoten besuchen, um alle mit Eingangsgrad 0 zu finden:  $O(n)$
- Anschließend wird jede Kante einmal verfolgt (um den Eingangsgrad ihres Zielknotens zu reduzieren):  $O(m)$

Insgesamt sind für das topologische Sortieren also  $O(n + m)$  Schritte notwendig. Ob dieser Aufwand auch realisierbar ist, hängt von der Graphrepräsentation ab. Mit Adjazenzlisten lässt sich dieser Algorithmus mit Aufwand  $O(n + m)$  tatsächlich realisieren, mit einer Repräsentation als Adjazenzmatrix benötigt nur schon das Finden aller Kanten  $O(n^2)$  Schritte.

## 7.6. Depth-First-Search (DFS)<sup>3</sup>

### 7.6.1. Graphen traversieren

Programme können nicht einfach Graphen „anschauen“. Sie müssen sich über Knoten und Kanten „entlangtasten“, vergleichbar mit der Suche in einem Labyrinth. Dieses „Entlangtasten“ ist für spezielle Graphen – nämlich Bäume – bereits bekannt. Für allgemeine Graphen lässt sich die Idee der *pre-order Traversierung* geeignet anpassen.

<sup>2</sup> *Gerichtete azyklische Graphen*, engl. *Directed Acyclic Graph* (DAG) sind eine oft vorkommende Art von Graphen.

<sup>3</sup> auch als *Tiefensuche* bezeichnet

Im Gegensatz zu Bäumen muss man bei allgemeinen Graphen mit folgender Situation umgehen:

- Es können mehrere Pfade von einem Knoten zu einem anderen Knoten führen.
- Enthält der Graph einen Zyklus, gilt es zu verhindern, dass im Kreis gelaufen wird.

Dazu drängt sich folgende Lösung auf:

- Besuchte Knoten markieren.
- Jeder Kante nur einmal folgen.

Die Teifensuche strebt danach möglichst rasch die weit entfernten Knoten zu erreichen und wird deswegen als *Depth-First-Search* (DFS) oder *Tiefensuche* bezeichnet. Gegensatz dazu ist *Breadth-First-Search* oder *Breitensuche*, die danach strebt, parallel verschiedene Wege auszuprobieren (s. 7.7.2).

Wie die Traversierung von Bäumen lässt sich die Tiefensuche am besten als rekursives Verfahren formulieren (die unterstrichenen Zeilen sind hierbei neu gegenüber der Baum-Traversierung):

```

1. Alle Knoten als bisher nicht besucht markieren
2. dfs(startKnoten) aufrufen


dfs(Vertex v):
    falls v nicht als besucht markiert ist:
        1. v „besuchen“ (verarbeiten, ausgeben, etc.)
        2. v als besucht markieren
        3. Für alle Vertex w zu denen eine Kante von v führt: dfs(w) aufrufen
    
```

### 7.6.2. Anwendung: Zusammenhangskomponenten finden

Graphen-Traversierung eignet sich beispielsweise, um zu prüfen ob ein Graph zusammenhängend ist.

**Definition:** Ein ungerichteter Graph ist *zusammenhängend*, falls es für jedes Paar von verschiedenen Knoten einen verbindenden Pfad gibt.

Um zu prüfen, ob ein Graph zusammenhängend ist, kann man eine Traversierung mit *DFS* ausgehend von einem beliebigen Knoten starten. Alle von diesem Knoten erreichbaren Knoten sind anschliessend als *besucht* markiert:



1. Alle Knoten als bisher *nicht besucht* markieren
2. *dfs(v)* für irgendeinen Knoten *v* aufrufen
3. Sequenzielle Suche in der Menge aller Knoten nach dem ersten, der *nicht besucht* wurde

Wird *kein* solcher gefunden, ist der Graph zusammenhängend.

Findet die abschliessende sequenzielle Suche einen noch *nicht besuchten* Knoten, kann von diesem aus erneut ein *dfs* gestartet werden. Iteriert man diesen Prozess, ergibt die Anzahl der *dfs*-Aufrufe die nötig sind, bis alle Knoten besucht sind, die Anzahl der *Zusammenhangskomponenten* des Graphen.

### 7.6.3. Anwendung: Spannbaum


Speichert man alle Kanten, die DFS benutzt, um zu bisher *nicht besuchten* Knoten zu kommen, erhält man einen Baum, der alle vom Startknoten aus erreichbaren Knoten des Graphen enthält, sowie die kleinstmögliche Menge an Kanten um diese zu verbinden.<sup>4</sup> Ein solcher Baum, heisst *Spanning Tree* oder *Spannbaum*.

<sup>4</sup> Jeder Baum mit *n* Knoten enthält genau *n-1* Kanten – eine „hin-führende“ für jeden Knoten ausser der Wurzel


Um während einer Tiefensuche den Spannbaum zu speichern, erweitert man am besten die *dfs*-Operation aus 7.6.1 folgendermassen:

```
dfs(Vertex v):
  falls v nicht als besucht markiert ist:
    1. v als besucht markieren
    2. Für alle Vertex w zu denen eine Kante von v führt:
        Falls w nicht als besucht markiert ist:
            a. Kante <v, w> dem Graphen tree hinzufügen
            b. dfs(w) aufrufen
```

Die asymptotische Laufzeitkomplexität verändert sich dadurch nicht.



dfs('A') führt zu folgendem Spannbaum:



## 7.7. Kürzester Weg

### 7.7.1. Definitionen

**Definition:** Distanz zweier Knoten:

$D(x, y)$  = Länge eines kürzesten Weges von  $x$  nach  $y$ , falls einer existiert;  $\infty$  sonst

**Definition:** Länge eines Weges:

- a) In ungewichteten Graphen: Anzahl Kanten
- b) In gewichteten Graphen:

$$\sum w_{x,y} \quad \text{wobei } w_{x,y} = \begin{cases} 0 & \text{falls } x = y \\ \text{Gewicht von } \langle x, y \rangle & \text{falls } \langle x, y \rangle \in E \\ \infty & \text{sonst} \end{cases}$$

### 7.7.2. Ungewichtete Graphen: Breadth-First-Search (BFS)<sup>5</sup>

Während *Tiefensuche* (DFS – s. 7.6) möglichst schnell die Tiefen eines Graphen zu ergründen sucht, geht *Breitensuche* oder *Breadth First Search* (BFS) schichtweise vor. Ausgehend von einem Startpunkt werden zuerst alle Knoten markiert, deren Distanz 1 ist, dann jene mit Distanz 2 usw.

Um dies Laufzeit-effizient tun zu können, verwendet man am besten eine Warteschlange (Queue), in der alle bereits *entdeckten* aber noch nicht *besuchten* Knoten gespeichert werden. Bearbeitet wird dann jeweils der erste Knoten der Liste.

Um den kürzesten Weg von einem Startknoten zu allen übrigen Knoten zu bestimmen, merken wir uns zu jedem Knoten eine Distanzangabe.

**Algorithmus im Pseudo-Code:**

1. Bei allen Knoten die Distanzangabe auf  $\infty$  setzen
2. Beim Startknoten die Distanzangabe auf 0 setzen
3. Startknoten hinten an die Warteschlange *erreichbar* anfügen
4. Solange Warteschlange *erreichbar* nicht leer ist:
  - a. Vordersten Knoten  $v$  aus der Warteschlange entnehmen
  - b. Für alle Knoten  $w$  zu denen eine Kante von  $v$  führt:
 

Falls die Distanzangabe dieses Knotens  $\infty$  ist (war er bisher nicht erreichbar):  
Distanzangabe von  $w = 1 + \text{Distanzangabe von } v$

<sup>5</sup> auch als *Breitensuche* bezeichnet

**Beispiel:** Wir führen den kürzeste Wege Algorithmus aus und bestimmen Sie die Distanz von jedem Knoten zum Startknoten 2.

Es kann hilfreich sein, die Distanzen der Knoten in eine Tabelle zu schreiben. Initial würde die dann so aussehen:

2	5	6	3	12	7	9	8
0	$\infty$	$\infty$	$\infty$	$\infty$	$\infty$	$\infty$	$\infty$

Und *erreichbar* = {2}.

Nach dem ersten Durchlauf durch Schritt 4 gilt dann:

2	5	6	3	12	7	9	8
0	1	$\infty$	$\infty$	$\infty$	$\infty$	1	$\infty$

Und *erreichbar* = {5, 9}.

Nach dem zweiten Durchlauf:

2	5	6	3	12	7	9	8
0	1	2	$\infty$	2	$\infty$	1	$\infty$

Und *erreichbar* = {9, 6, 12}.

Nach dem dritten Durchlauf:

2	5	6	3	12	7	9	8
0	1	2	$\infty$	2	$\infty$	1	2

Und *erreichbar* = {6, 12, 8}.

Nach dem vierten Durchlauf:

2	5	6	3	12	7	9	8
0	1	2	3	2	$\infty$	1	2


Und *erreichbar* = {12, 8, 3}.

Nach dem fünften Durchlauf:

2	5	6	3	12	7	9	8
0	1	2	3	2	3	1	2

Und *erreichbar* = {8, 3, 7}.

Nun werden noch alle Knoten aus der Warteschlange entfernt, an den Distanzen ändert sich allerdings nichts mehr.



### 7.7.3. Gewichtete Graphen: Algorithmus nach Dijkstra (Edsger W. Dijkstra, 1959)

Sind die Kanten gewichtet, muss man diese Kantengewichte als Distanzen bei der Suche berücksichtigen. Damit wird die allgemeine Breitensuche aus etwas komplizierter. Eine Möglichkeit ist wie folgt:

1. Es wird eine Tabelle/Liste mit allen Knoten geführt. Pro Knoten werden 3 Dinge gespeichert:
  - *bekannt*: (*false*)  
Ist die minimale Distanz vom Ausgangsknoten zu diesem Knoten bereits bekannt?
  - *dist*: (0 für Startknoten,  $\infty$  sonst)  
Die bisher bekannte kleinste Distanz
  - *via*: (? oder *null*)  
Der vorhergehende Knoten auf dem kürzesten Pfad vom Ausgangsknoten

Die Werte in Klammern geben die Initialisierung der Tabelle an.
2. Solange sich in der Tabelle Knoten befinden mit *bekannt* = *false* und *dist* <  $\infty$ 
  - a. Den Knoten *v* aus der Tabelle suchen der unter allen mit *bekannt* = *false* den kleinsten Wert für *dist* hat.
  - b. *v.bekannt* auf *true* setzen, denn es kann keinen noch kürzeren Weg zu *v* geben.
  - c. Für jeden Knoten *w*, der von *v* aus direkt erreichbar ist (d.h. es gibt Kante  $\langle v, w \rangle$ ):
    - i. Distanz berechnen, die *w* vom Startknoten entfernt mit dem Pfad *via* *v*:  
 $int\ d = v.dist + \text{Kantengewicht von } \langle v, w \rangle$
    - ii. Ist diese Distanz *d* kleiner als der Wert, der für *w.dist* bisher bekannt ist, so wurde ein kürzerer Weg zum Knoten *w* gefunden. Dieser führt über *v* nach *w*. Das wird in der Tabelle eingetragen.  
 $if\ (d < w.dist)\ \{ w.dist = d;\ w.via = v;\ }$

Dieser Algorithmus findet die kürzesten Wege vom Startknoten zu allen erreichbaren Knoten. Es ist kein Algorithmus bekannt, der mit weniger Aufwand nur den kürzesten Weg zwischen 2 Knoten findet. Dieser Algorithmus funktioniert allerdings nur für Graphen mit nicht-negativen Kantengewichten.

#### Aufwandsanalyse:

Es sei *n* die Anzahl der Knoten und *m* die Anzahl der Kanten. Wir nehmen an, dass der Graph keine Mehrfachkanten hat und keine Schlingen.

Der Aufwand für die einzelnen Schritte des Algorithmus ist:

Schritt 1: Tabelle initialisieren dauert  $O(n)$


Schritt 2 a: Eine Suche dauert  $O(n)$ , insgesamt wird *n* mal gesucht

Schritt 2 c: Jede Kante wird während des Algorithmus einmal betrachtet:  $O(m)$

Insgesamt also:  $O(n^2)$ . Bei diesem Aufwand spielt es keine Rolle, ob der Graph als Adjazenzlisten oder als Adjazenzmatrix vorliegt.

Man kann Schritt 2a durch geschickte Wahl einer Hilfsdatenstruktur beschleunigen (siehe Programmieraufgabe 2: Implementieren des Dijkstra-Algorithmus<sup>6</sup>), indem für die Knotentabelle eine Prioritätswarteschlange verwendet. Schritt 2a wäre dann eine *extractMin* Operation, in Schritt 2cii würden *decreaseKey* Operationen ausgeführt. Während 2a damit günstiger wird (z.B.  $O(\log n)$  mit Heap), wird Schritt 2cii teurer (z.B.  $O(\log n)$  mit Heap, pro Kante). Insgesamt verringert sich dann die Laufzeit zu  $O((n + m) \log n)$ , wenn der Graph als Adjazenzlisten gegeben ist.

**Aufgabe:** Berechnen Sie den kürzesten Weg von A nach E.



<sup>6</sup> „07-7 Graphen Implementierung DFS und Dijkstra-Algorithmus Arbeitsblatt“